

# Análisis Exploratorio y Descriptivo de Datos

Preferencias Tecnológicas en Población Simulada

Dr. Horacio Irán Solís Cisneros  
Universidad Politécnica de Chiapas  
Minería de Datos

## **Integrantes:**

Daniel Peregrino Perez - 223216  
Raul Abigail Mimiaga Vasquez -223265  
Alejandro Chanona Vazquez - 223248

30 de septiembre de 2025

## Resumen

Este reporte presenta un Análisis Exploratorio de Datos (EDA) aplicado a una encuesta realizada a un grupo diverso de profesionales y familiares involucrados en la enseñanza de la lectoescritura. El objetivo del estudio es transformar los datos de la encuesta en conocimiento accionable para comprender a fondo las percepciones, necesidades y desafíos de los usuarios, justificando así el diseño y desarrollo de una herramienta digital de apoyo.

La metodología comprendió la recolección de datos a través de una encuesta en línea (Google Forms), un riguroso preprocesamiento que incluyó la estandarización de categorías y el manejo de respuestas de selección múltiple, y un análisis multifacético. Se emplearon estadísticas descriptivas, visualizaciones univariadas como gráficos de barras, y análisis de relaciones bivariadas mediante heatmaps de frecuencia y tablas de contingencia para identificar patrones entre segmentos de usuarios y sus preferencias.

La interpretación de los datos revelan una clara segmentación en las necesidades de los dos perfiles de usuario predominantes: los **Maestros** y los **Familiares/Tutores**. Mientras que el primer grupo prioriza funcionalidades orientadas a la eficiencia y el seguimiento del progreso, como la retroalimentación automática y los niveles de dificultad, el segundo grupo valora más las características que fomentan la motivación y el compromiso, como la gamificación y las notificaciones. Al igual se puede notar que mientras los alumnos en un rango de edad mas pequeño se enfrentan mayoritariamente al mismo problema ("no poder trazar correctamente") los usuarios con una edad mas avanzada se enfrentan a diversos problemas. El análisis de co-ocurrencia demuestra una fuerte correlación entre las frustraciones reportadas (ej. requiere supervision constante") y las funcionalidades más deseadas (ej. "notificaciones"), validando la demanda de soluciones específicas.

A partir de estos hallazgos, se delinean perfiles de usuario (TIPO DE PERFIL: 'Familiar' y 'Maestro') concretos que justifican requisitos cruciales del sistema, como una interfaz intuitiva y adaptable, un robusto sistema de feedback y componentes de engagement. Este EDA demuestra cómo un enfoque estructurado basado en datos es fundamental para sentar las bases de un sistema que responda a las necesidades reales y diversas de sus futuros usuarios.

## 1. Introducción

El desarrollo de habilidades de lectoescritura constituye una base fundamental en el proceso educativo de cualquier individuo. Sin embargo, para muchas personas, especialmente aquellas con dificultades de aprendizaje o en etapas tempranas de desarrollo, este proceso

presenta desafíos significativos que requieren un apoyo constante, personalizado y motivador. Los métodos tradicionales, aunque valiosos, a menudo carecen de la capacidad de proporcionar retroalimentación inmediata, adaptarse dinámicamente al ritmo de cada aprendiz o mantener un alto nivel de compromiso a largo plazo.

Las herramientas actuales utilizadas por educadores y familiares van desde cuadernos de caligrafía y plantillas hasta aplicaciones genéricas. Un análisis de las frustraciones asociadas a estos métodos revela problemas recurrentes: la necesidad de una supervisión constante, la falta de elementos motivadores y la dificultad para medir el progreso de manera objetiva. Esta brecha entre las herramientas disponibles y las necesidades reales de los usuarios crea una oportunidad clara para el desarrollo de soluciones tecnológicas innovadoras.

La proliferación de dispositivos táctiles como tabletas y teléfonos móviles ofrece una plataforma ideal para crear experiencias de aprendizaje interactivas y multisensoriales. Una aplicación bien diseñada puede analizar los trazos en tiempo real, ofrecer correcciones instantáneas, gamificar el proceso de práctica a través de recompensas y adaptar los ejercicios a los errores más comunes de cada usuario, convirtiendo la práctica en una actividad atractiva en lugar de una tarea repetitiva.

En este contexto, el presente reporte detalla un Análisis Exploratorio de Datos (EDA) aplicado a una encuesta diseñada para capturar las percepciones y preferencias de los futuros usuarios de una herramienta digital de apoyo a la lectoescritura. El objetivo principal de este análisis es transformar las opiniones y experiencias de los encuestados en requisitos de sistema claros y justificados. A través de la segmentación de usuarios, el ranking de funcionalidades y el análisis de correlaciones, se busca comprender a fondo las necesidades prioritarias del público objetivo para guiar el diseño de una solución que sea no solo tecnológicamente robusta, sino también verdaderamente útil, usable y deseable.

## **Objetivos**

### **Objetivo General**

Determinar las funcionalidades prioritarias, caracterizar los perfiles de usuario clave y establecer los requisitos de usabilidad y diseño para justificar y guiar el desarrollo de una herramienta digital de apoyo a la lectoescritura, basándose en el análisis de las necesidades y preferencias expresadas por los encuestados.

### **Objetivos Específicos**

- Describir la distribución de las respuestas de la encuesta mediante métricas estadísticas y visualizaciones para obtener una comprensión general de los datos.

- Segmentar a los encuestados en grupos significativos (ej. Maestros vs. Familiares, Entorno Escolar vs. Hogar) para identificar diferencias en sus necesidades y preferencias.
- Explorar y visualizar las correlaciones entre las frustraciones actuales de los usuarios y las funcionalidades que más valoran, con el fin de alinear el desarrollo del producto con la resolución de problemas reales.
- Identificar y jerarquizar las funcionalidades más deseadas y las características de accesibilidad esenciales para definir un roadmap de desarrollo priorizado.
- Sintetizar los hallazgos para construir perfiles de usuario (User Personas) accionables que sirvan como base para el diseño centrado en el usuario (UX/UI).
- Analizar las principales dificultades de lectoescritura reportadas y su asociación con variables clave como el entorno de uso (Escolar vs. Hogar) y las funcionalidades preferidas por los usuarios, con el fin de priorizar el desarrollo de características que ofrezcan soluciones directas a los problemas más comunes.

## Metodología Utilizada

El enfoque aplicado en este Análisis Exploratorio de Datos (EDA) se estructuró en las siguientes etapas clave, priorizando la claridad y la obtención de insights accionables:

- **Adquisición y Recolección del Dataset**

El dataset se obtuvo mediante una encuesta en línea implementada con Google Forms, distribuida a profesionales (maestros ) y familiares involucrados en el proceso de enseñanza de la lectoescritura.

- **Preprocesamiento y Transformación de Datos**

Esta etapa fue fundamental para asegurar la calidad y consistencia de los datos. Se realizaron las siguientes tareas: renombrado de columnas a un formato estandarizado (`snake_case`), unificación de categorías de respuesta (ej. distintos tipos de "Profesor"), y la creación de variables calculadas como `funcionalidad_preferida` para identificar la máxima valoración por usuario. Se implementaron técnicas para manejar respuestas de selección múltiple, permitiendo su análisis cuantitativo.

- **Análisis Descriptivo**

Se calcularon medidas de frecuencia y tendencia central (moda) para las variables categóricas. Se generaron gráficos de barras para visualizar la distribución de las respuestas y la composición de los segmentos de usuarios.

- **Análisis Bivariado y Multivariado**

Para descubrir relaciones entre variables, se utilizaron tablas de contingencia (crosstabs) que fueron visualizadas a través de heatmaps de frecuencia. Esta técnica fue crucial para analizar la correlación entre dos variables categóricas (ej. Rol vs. Frustraciones).

- **Interpretación y Síntesis de Hallazgos**

Los resultados de los análisis descriptivos y bivariados se integraron para construir perfiles de usuario (User Personas) detallados. Estos perfiles resumen las características, necesidades y motivaciones de los segmentos clave identificados.

Esta metodología, aplicada a datos reales de una encuesta, demuestra un flujo de trabajo estructurado que transforma respuestas cualitativas y cuantitativas en una base de evidencia sólida para la ingeniería de requisitos de software.

## Hipótesis del Análisis

A partir de los objetivos del estudio, se plantearon las siguientes hipótesis exploratorias para guiar el análisis e identificar patrones de comportamiento en los datos de la encuesta:

- **H1:** El rol del usuario (Maestro vs. Familiar/Tutor) es el principal factor de segmentación que determina las preferencias de funcionalidades. Se espera que los profesionales valoren más las herramientas de seguimiento y eficiencia, mientras que los familiares prioricen el engagement y la motivación.
- **H2:** Existe una fuerte correlación entre las frustraciones reportadas con las herramientas actuales (el "dolor") y las soluciones funcionales más deseadas en la nueva aplicación (la "solución"). Por ejemplo, la frustración por la "falta de motivación" se asociará con una alta valoración de la "gamificación".
- **H3:** El entorno de apoyo donde se utilizará la herramienta (Escolar vs. Hogar) influirá en las prioridades. Se anticipa que en el entorno escolar se valorarán más los datos para reportes, mientras que en el hogar se preferirán las notificaciones y recordatorios de práctica.

Estas hipótesis tienen un carácter exploratorio y su propósito es dirigir la investigación dentro del dataset. Se investigarán a través de la visualización de distribuciones cruzadas y heatmaps de frecuencia para observar si la evidencia empírica en los datos respalda o contradice estas suposiciones iniciales.

En las siguientes secciones se detallan las características del dataset, las técnicas de análisis aplicadas y los hallazgos obtenidos a partir del procesamiento y visualización de los datos.

## 1. Descripción del Dataset

El dataset utilizado en este análisis fue recolectado a través de una encuesta en línea con Google Forms, capturando las respuestas de 32 individuos involucrados en la enseñanza de la lectoescritura (maestros, terapeutas y familiares). Las variables buscan caracterizar el perfil del usuario, sus herramientas, necesidades y preferencias funcionales.

A continuación, se presenta el diccionario de datos completo con todas las variables utilizadas en el análisis, junto a su descripción y tipo.

| p0.25                       | p0.55                                                               | p0.15                 |
|-----------------------------|---------------------------------------------------------------------|-----------------------|
| Variable (Apodo)            | Descripción                                                         | Tipo                  |
| rol                         | Rol principal del encuestado en el proceso educativo.               | Nominal               |
| edad                        | Rango de edad del encuestado.                                       | Ordinal               |
| entorno_apoyo               | Contexto principal donde se brinda el apoyo.                        | Nominal               |
| edad_alumnos                | Rango de edad de los alumnos con los que trabaja.                   | Ordinal               |
| dificultad                  | Principales dificultades de lectoescritura observadas.              | Categórica (Múltiple) |
| herramientas_actuales       | Herramientas y actividades usadas con mayor frecuencia.             | Categórica (Múltiple) |
| utilidad_feedback_inmediato | Valoración de la utilidad de la retroalimentación inmediata (1-5).  | Ordinal               |
| frustraciones               | Aspectos más frustrantes de las herramientas actuales.              | Categórica (Múltiple) |
| info_util_app               | Tipo de información que sería más útil en la app.                   | Categórica (Múltiple) |
| funcionalidad_clave         | La única funcionalidad considerada como la más importante.          | Categórica (Única)    |
| accesibilidad_esencial      | Adaptaciones de accesibilidad consideradas esenciales.              | Categórica (Múltiple) |
| pago                        | Disposición a pagar por una versión completa de la app.             | Ordinal               |
| utilidad_feedback_auto      | Valoración de la retroalimentación automática con puntuación (1-5). | Ordinal               |
| utilidad_modos_paciente     | Valoración de un modo de usuario con nivel adaptativo (1-5).        | Ordinal               |
| utilidad_gamificacion       | Valoración de la incorporación de contenido gamificado (1-5).       | Ordinal               |

formato\_feedback Formato de retroalimentación preferido para el estudiante. Categórica (Única)

datos\_utiles\_perfil Datos adicionales útiles en un perfil de multi-usuario. Categórica (Múltiple)

utilidad\_niveles Valoración de tener niveles de dificultad progresivos (1-5). Ordinal

utilidad\_notificaciones Valoración de recibir notificaciones o recordatorios (1-5). Ordinal

Diccionario de datos completo de la encuesta.

El conjunto de datos final consta de 32 registros y un total de 19 variables analizadas tras el preprocesamiento. El dataset está compuesto por una mezcla rica de tipos de variables: **Nominales**, **Ordinales** y de **Selección Múltiple**, lo que requirió un análisis multifacético centrado en frecuencias, tablas de contingencia y visualizaciones de co-ocurrencia para extraer relaciones significativas.

## 2. Limpieza y Preprocesamiento

El preprocesamiento fue mínimo debido a que los datos fueron generados sintéticamente bajo control de calidad. Sin embargo, se replicaron pasos habituales del flujo de trabajo de análisis de datos.

### Conversión de tipos de datos

```
1 df['Edad'] = df['Edad'].astype(int)
2 df['Género'] = df['Género'].astype('category')
3 df['Ocupación'] = df['Ocupación'].astype('category')
```

### Verificación de valores nulos

```
1 print(df.isnull().sum())
```

Dado que los datos son simulados, no se encontraron valores faltantes. No obstante, este paso es obligatorio en flujos reales, ya que variables con muchos valores nulos pueden requerir imputación o eliminación.

### Codificación de variables categóricas

Para futuros modelos predictivos o análisis estadísticos, puede ser necesario codificar variables no numéricas. Por ejemplo:

```

1 df['Frecuencia_Tecnologia'] = df['Frecuencia_Tecnologia'].map({
2     'Baja': 1, 'Media': 2, 'Alta': 3
3 })
4
5 df['Interes_AI'] = df['Interes_AI'].map({
6     'Nada interesado': 1,
7     'Poco interesado': 2,
8     'Interesado': 3,
9     'Muy interesado': 4
10 })

```

Estos valores permiten representar preferencias ordinales respetando su jerarquía lógica.

### 3. Análisis Descriptivo

El análisis descriptivo permite conocer la distribución de las variables presentes en el dataset. Dado que la mayoría de las variables son categóricas u ordinales, se utilizan frecuencias absolutas y relativas, acompañadas de visualizaciones con gráficos de barras, diagramas de caja y tablas resumen. A continuación, se analiza cada grupo de variables por separado.

#### Edad (Variable numérica discreta)

Se calcula la media, mediana y desviación estándar para tener una idea general de la distribución etaria de los participantes.

```

1 print(df['Edad'].describe())

```

Para visualizar la distribución se utiliza un histograma con línea de densidad:

```

1 import seaborn as sns
2 import matplotlib.pyplot as plt
3
4 sns.histplot(data=df, x="Edad", bins=10, kde=True)
5 plt.title("Distribución de Edad")
6 plt.xlabel("Edad")
7 plt.ylabel("Frecuencia")
8 plt.show()

```

Esto permite detectar sesgos, asimetrías o agrupaciones por rango de edad.

- Rango de edad: 18 a 60 años.

- Media y desviación estándar reportadas en el análisis exploratorio.




Figura 1: Distribución de edad de los encuestados. Se observa un rango balanceado con ligera concentración entre los 25 y 35 años.

## Género

Esta variable es categórica nominal. El análisis se realiza por frecuencias:

```
1 print(df['Género'].value_counts())
2 print(df['Género'].value_counts(normalize=True) * 100)
```

Gráficamente:

```
1 sns.countplot(data=df, x="Género")
2 plt.title("Distribución por Género")
3 plt.ylabel("Frecuencia")
4 plt.show()
```

## Ocupación

Variable categórica nominal útil para segmentar los datos. El conteo permite identificar el grupo predominante.

```

1 sns.countplot(data=df, x="Ocupación")
2 plt.title("Distribución por Ocupación")
3 plt.ylabel("Frecuencia")
4 plt.xticks(rotation=45)
5 plt.show()

```

## Nivel Educativo

Aunque es una variable categórica, posee un orden lógico (ordinal). Se recomienda definir el orden antes de graficar.

```

1 orden_educacion = ['Secundaria', 'Preparatoria', 'Licenciatura', 'Posgrado']
2 df['Nivel_Educativo'] = pd.Categorical(df['Nivel_Educativo'],
3                                     categories=orden_educacion,
4                                     ordered=True)
5
6 sns.countplot(data=df, x="Nivel_Educativo",
7               order=orden_educacion)
8 plt.title("Nivel Educativo de los Participantes")
9 plt.ylabel("Frecuencia")
10 plt.show()

```

## Frecuencia de Uso de Tecnología

Esta variable ordinal refleja el grado de exposición a herramientas tecnológicas.

```

1 orden_frecuencia = ['Baja', 'Media', 'Alta']
2 sns.countplot(data=df, x="Frecuencia_Tecnologia", order=orden_frecuencia)
3 plt.title("Frecuencia de Uso Tecnológico")
4 plt.ylabel("Frecuencia")
5 plt.show()

```

## Interés en Inteligencia Artificial

Otra variable ordinal clave para segmentar perfiles.

```

1 orden_interes = ['Nada interesado', 'Poco interesado', 'Interesado', 'Muy
  ↳ interesado']
2 sns.countplot(data=df, x="Interes_AI", order=orden_interes)
3 plt.title("Interés en Inteligencia Artificial")

```

```
4 plt.xticks(rotation=30)
5 plt.ylabel("Frecuencia")
6 plt.show()
```

## Dispositivo Tecnológico Favorito

Permite observar tendencias en preferencias tecnológicas.

```
1 sns.countplot(data=df, x="Dispositivo_Favorito")
2 plt.title("Dispositivo Tecnológico Favorito")
3 plt.xticks(rotation=30)
4 plt.ylabel("Frecuencia")
5 plt.show()
```

## Síntesis General

Las visualizaciones y estadísticas descriptivas mostraron que:

- Las edades se distribuyen aproximadamente de forma uniforme entre 18 y 60 años.
- El grupo más frecuente es el de estudiantes con nivel educativo de licenciatura.
- Predomina el uso alto de tecnología y un interés significativo en inteligencia artificial.
- El dispositivo favorito más común es el smartphone, seguido por la laptop.

Estos patrones sugieren un perfil joven, tecnológicamente activo e interesado en IA, lo que resulta útil para estrategias de segmentación educativa o comercial.

## 4. Análisis de relaciones entre variables de interés

En esta sección se analizan las relaciones entre pares de variables, tanto categóricas como numéricas. El objetivo es identificar asociaciones relevantes que permitan inferencias útiles para segmentación, predicción o estrategias de comunicación tecnológica.

### Interés en IA vs. Frecuencia de Uso Tecnológico

Ambas variables son ordinales. Se visualizan mediante un gráfico de barras segmentado.

```

1 orden_interes = ['Nada interesado', 'Poco interesado', 'Interesado', 'Muy
  ↳ interesado']
2 orden_frecuencia = ['Baja', 'Media', 'Alta']
3
4 sns.countplot(data=df, x='Interes_AI', hue='Frecuencia_Tecnologia',
5               order=orden_interes, hue_order=orden_frecuencia)
6 plt.title("Interés en IA según Frecuencia de Uso Tecnológico")
7 plt.ylabel("Número de personas")
8 plt.xticks(rotation=30)
9 plt.show()

```

Se observa que el interés en IA tiende a ser mayor entre quienes reportan un uso frecuente de tecnología. Esto sugiere que la familiaridad tecnológica se relaciona con una actitud más favorable hacia tecnologías emergentes.




Figura 2: Distribución del interés en IA segmentado por la frecuencia de uso de tecnología. Se observa mayor interés entre quienes reportan uso frecuente.

## Edad vs. Dispositivo Favorito

Una de las preguntas clave es si la edad influye en las preferencias tecnológicas de los encuestados. Para responder a esto, se comparó la variable Edad con Dispositivo\_Favorito,

utilizando un diagrama de caja (boxplot), que permite visualizar la mediana, la dispersión y los posibles valores atípicos en cada categoría. En esta figura de hecho, se detecta mayor preferencia por smartphones en grupos jóvenes, y laptops o PCs en mayores.




Figura 3: Boxplot de edad por dispositivo favorito.

Este cruce permite identificar si la edad influye en la preferencia tecnológica. Se utiliza un boxplot:

```
1 sns.boxplot(data=df, x="Dispositivo_Favorito", y="Edad")
2 plt.title("Edad según Dispositivo Favorito")
3 plt.xticks(rotation=30)
4 plt.show()
```

La edad media varía ligeramente entre tipos de dispositivo. Los usuarios de smartphone tienden a ser más jóvenes, mientras que el uso de PC de escritorio es más común en edades mayores.

## Correlaciones entre Variables Ordinales Codificadas

Se recodifican variables ordinales para calcular la correlación de Spearman.

```
1 # Codificación ordinal
2 df['Interes_AI_C'] = df['Interes_AI'].map({
3     'Nada interesado': 1,
4     'Poco interesado': 2,
```

```

5     'Interesado': 3,
6     'Muy interesado': 4
7 })
8
9 df['Frecuencia_C'] = df['Frecuencia_Tecnologia'].map({
10     'Baja': 1,
11     'Media': 2,
12     'Alta': 3
13 })
14
15 # Correlación de Spearman
16 corr = df[['Edad', 'Interes_AI_C', 'Frecuencia_C']].corr(method='spearman')
17
18 # Visualización
19 import seaborn as sns
20 import matplotlib.pyplot as plt
21
22 sns.heatmap(corr, annot=True, cmap="coolwarm", fmt=".2f")
23 plt.title("Matriz de Correlación (Spearman)")
24 plt.show()

```

Existe una correlación positiva moderada entre la frecuencia de uso tecnológico y el interés en IA. La edad muestra una correlación débil negativa con esas variables, lo que refuerza la idea de que los más jóvenes son más propensos a tener actitudes tecnológicas positivas.

## Cruces Categóricos: Ocupación y Nivel Educativo

Para analizar la relación entre dos variables categóricas, se emplea una tabla de contingencia.

```

1 tabla = pd.crosstab(df['Ocupación'], df['Nivel_Educativo'], margins=True)
2 print(tabla)

```

La mayoría de los estudiantes presentan niveles de licenciatura o preparatoria, mientras que los docentes y profesionales se concentran en niveles más altos. Esto permite inferir asociaciones relevantes entre perfil laboral y escolaridad.

## 5. Hallazgos

Los principales hallazgos del análisis están respaldados por las siguientes visualizaciones clave:

### Frecuencia de Tecnología e Interés en IA




Figura 4: Relación entre interés en inteligencia artificial y frecuencia de uso de tecnología.

## Edad según Dispositivo Favorito




Figura 5: Preferencia tecnológica por edad. Los usuarios más jóvenes prefieren smartphones.

## Correlación entre variables ordinales




Figura 6: Matriz de correlación de Spearman entre edad, interés en IA y frecuencia tecnológica.

Estas gráficas resumen las relaciones más importantes entre las variables encuestadas, confirmando tendencias esperadas en cuanto a afinidad tecnológica y edad, así como patrones útiles para segmentación futura.

## Interés en Inteligencia Artificial

- El interés en IA se relaciona directamente con la frecuencia de uso tecnológico: quienes usan tecnología más intensamente tienden a estar más interesados en IA.
- Se detecta una relación débilmente negativa entre edad e interés por IA, lo que sugiere que las generaciones más jóvenes están más abiertas a esta tecnología.

## Combinaciones significativas

- Individuos con ocupación profesional y alto nivel educativo también muestran frecuencias tecnológicas altas.
- La combinación de alta frecuencia tecnológica y fuerte interés en IA representa un segmento estratégico para intervenciones de adopción tecnológica, formación especializada o difusión de innovaciones.

Estos hallazgos permiten segmentar la población en perfiles útiles para estrategias de diseño de servicios tecnológicos, recomendaciones personalizadas, o análisis de comportamiento digital. También ofrecen una base sólida para el desarrollo de modelos predictivos o estudios de causalidad más avanzados.

## 6. Conclusiones

Este análisis exploratorio permitió caracterizar, segmentar e interpretar un conjunto de datos simulados con base en siete variables sociodemográficas y tecnológicas. A pesar de su origen sintético, los datos fueron tratados como si provinieran de una encuesta real, siguiendo prácticas estándar de minería de datos.

A partir del análisis descriptivo y multivariado, se identificaron relaciones clave como:

- Alta correlación entre el uso frecuente de tecnología y el interés por la inteligencia artificial.
- Diferencias claras en la elección del dispositivo favorito según el rango de edad.
- Segmentación ocupacional coherente con el nivel educativo declarado.

El uso de visualizaciones fue fundamental para descubrir patrones que no serían evidentes con estadística tabular. Por ejemplo, el boxplot de edad vs. dispositivo favorito y el mapa de calor de correlación aportaron claridad visual sobre perfiles de usuario y vínculos entre variables.

## **Implicaciones prácticas**

Los resultados son útiles para:

- Diseñar programas de formación tecnológica adaptados a perfiles demográficos.
- Identificar segmentos potenciales para difusión de herramientas de IA.
- Servir de base para proyectos de recomendación, segmentación de mercado o predicción de afinidad tecnológica.

## **Reflexiones metodológicas**

Aunque los datos fueron generados artificialmente, el análisis demostró la aplicabilidad de metodologías EDA para:

1. Validar pipelines de análisis.
2. Diseñar dashboards o visualizaciones interactivas.
3. Practicar procesos reales de limpieza, codificación y exploración.

## **Líneas futuras**

Para consolidar este ejercicio, se propone:

- Repetir el análisis con datos reales recolectados mediante formularios o APIs educativas.
- Incorporar variables adicionales como ingreso, zona geográfica o hábitos digitales.
- Construir modelos predictivos a partir de las variables actuales, como regresiones logísticas o árboles de decisión.

Finalmente, este tipo de análisis permite consolidar competencias clave en minería de datos: desde la limpieza y exploración hasta la generación de conocimiento accionable.

## Anexos

### A. Diccionario de datos

| Variable              | Descripción                                            |
|-----------------------|--------------------------------------------------------|
| Edad                  | Edad del participante (18 a 60 años)                   |
| Género                | Género declarado (Masculino, Femenino, Otro)           |
| Ocupación             | Rol principal (Estudiante, Docente, Profesional, etc.) |
| Nivel_Educativo       | Último grado académico alcanzado                       |
| Frecuencia_Tecnologia | Nivel de uso de tecnología (Baja, Media, Alta)         |
| Interes_AI            | Grado de interés en Inteligencia Artificial            |
| Dispositivo_Favorito  | Tipo de dispositivo más utilizado                      |

Cuadro 1: Diccionario de variables del dataset simulado

### B. Fragmento del código utilizado

```
1 import pandas as pd
2 import seaborn as sns
3 import matplotlib.pyplot as plt
4
5 df = pd.read_csv("encuesta_simulada.csv")
6
7 sns.histplot(df['Edad'], bins=10, kde=True)
8 plt.title("Distribución de Edad")
9 plt.xlabel("Edad")
10 plt.ylabel("Frecuencia")
11 plt.show()
```

### C. Preguntas utilizadas en la encuesta simulada

1. ¿Cuál es tu edad?
2. ¿Con qué género te identificas?
3. ¿Cuál es tu ocupación principal?
4. ¿Cuál es tu nivel educativo más alto alcanzado?

5. ¿Con qué frecuencia utilizas herramientas tecnológicas en tu vida diaria?
6. ¿Cuál es tu nivel de interés en inteligencia artificial?
7. ¿Cuál de los siguientes dispositivos usas con mayor frecuencia?

Estas preguntas fueron utilizadas como base para simular el dataset, y reflejan dimensiones clave para estudios de segmentación tecnológica.

## D. Recomendaciones de reproducibilidad

- El conjunto de datos fue generado con la librería **Faker** en Python, asegurando control de distribución y diversidad de respuestas.
- Todas las visualizaciones se realizaron con **seaborn** y **matplotlib**.
- El análisis fue estructurado en Jupyter Notebook, y documentado en LaTeX usando el paquete **minted**.
- Para reproducir el experimento, se sugiere mantener las mismas categorías, tipos de variable y semilla aleatoria fija si se desea comparar versiones.

## Referencias