

Análisis Exploratorio y Descriptivo de Datos

REPORTE DE IMPLEMENTACIÓN ML NO SUPERVISADO PARA CLUSTERING

Dr. Horacio Irán Solís Cisneros
Universidad Politécnica de Chiapas
Minería de Datos

Integrantes:

Daniel Peregrino Perez - 223216

2 de noviembre de 2025

Resumen Ejecutivo

Este reporte presenta un análisis exhaustivo de los datos de nacimientos en México para el año 2024, obtenidos de la Dirección General de Información en Salud (DGIS). El objetivo principal del estudio es aplicar técnicas de Machine Learning no supervisado para transformar un vasto conjunto de datos demográficos y clínicos en perfiles de nacimiento accionables. El propósito es identificar patrones y estructuras ocultas que permitan segmentar la población de recién nacidos en grupos con características homogéneas, revelando así escenarios de riesgo y perfiles normativos que no son evidentes a simple vista.

La metodología se centró en un riguroso proceso de Análisis Exploratorio de Datos (EDA) y modelado. Se inició con la integración y consolidación de los datos, incluyendo la catalogación de variables categóricas para enriquecer el dataset. Posteriormente, se aplicaron técnicas de preprocesamiento avanzadas para preparar los datos para el modelado, tales como la imputación de valores faltantes y el escalado de características numéricas. El núcleo del análisis consistió en el entrenamiento y la comparación de tres algoritmos de clustering distintos: **K-Means** (utilizando la variante optimizada ‘MiniBatchKMeans’ para grandes datos), **Gaussian Mixture Models (GMM)** y **Density-Based Spatial Clustering of Applications with Noise (DBSCAN)**.

Los hallazgos revelan una clara segmentación de la población de nacimientos en perfiles bien definidos y significativos. El modelo GMM, por ejemplo, logró identificar ocho clústeres distintos, entre los que destacan: un perfil de **"Muy Alto Riesgo Médico"**, caracterizado por una baja edad gestacional, bajo peso y puntuaciones APGAR críticas; perfiles demográficos claros, como los **"Nacimientos Saludables (Varones)"** y **"Nacimientos Saludables (Mujeres)"**; y, de manera crucial, varios **clústeres de Calidad de Datos** que agrupan registros con información clave faltante (ej. Peso o APGAR no registrado), permitiendo aislar y cuantificar problemas en la recolección de datos.

El análisis comparativo de los algoritmos demostró la capacidad de K-Means y GMM para segmentar toda la población, mientras que DBSCAN ofreció una perspectiva complementaria al identificar un gran núcleo de "nacimientos normativos", varios clústeres satélite de alto interés y un conjunto de registros anómalos clasificados como ruido. Este EDA demuestra cómo la aplicación de técnicas no supervisadas es fundamental para descubrir patrones complejos en grandes datasets de salud pública, sentando las bases para futuras investigaciones, modelos predictivos y políticas de intervención focalizadas en los perfiles de mayor vulnerabilidad.

1. Introducción

La mortalidad neonatal es uno de los indicadores más sensibles de la salud pública de una nación. Un precursor fundamental de esta es la presencia de condiciones de alto riesgo al nacer, como la prematuridad, el bajo peso o dificultades de adaptación indicadas por bajas puntuaciones APGAR. Si bien los análisis tradicionales son valiosos, a menudo se basan en variables predefinidas y pueden pasar por alto subgrupos complejos cuyos perfiles de riesgo son multifactoriales y no evidentes a primera vista.

Los datos recolectados en los certificados de nacimiento constituyen una fuente de información de inmensa riqueza, detallando variables demográficas, socioeconómicas y clínicas. Sin embargo, la escala masiva del dataset de nacimientos de México para el año **2024** hace que la identificación manual de patrones latentes sea una tarea inviable. Esta brecha entre la disponibilidad de macrodatos y la capacidad de extraer conocimiento accionable crea una oportunidad idónea para la aplicación de técnicas de **Machine Learning No Supervisado**.

A diferencia de los modelos predictivos, los algoritmos de clustering no buscan una "respuesta correcta", sino que "escuchan" a los datos para descubrir segmentaciones naturales. Este enfoque permite que los datos revelen por sí mismos qué combinaciones de características definen distintos "escenarios de nacimiento". Podríamos descubrir, por ejemplo, que un perfil de cuidado prenatal tardío "estadísticamente distinto de uno de 'alto riesgo médico'", sin haber hecho esa suposición previamente.

El presente reporte detalla la aplicación de un riguroso análisis de clustering al dataset nacional de nacimientos de 2024. El objetivo es transformar este vasto conjunto de datos en perfiles empíricamente derivados y fáciles de interpretar. Mediante la comparación de tres algoritmos de clustering y el análisis profundo de los grupos resultantes, se busca identificar y caracterizar no solo los perfiles de riesgo, sino también los perfiles normativos y aquellos definidos por la calidad de los datos, sentando así las bases para futuras investigaciones y el diseño de intervenciones de salud pública más eficaces y focalizadas.

1.1. Objetivos

1.1.1. Objetivo General

Identificar y caracterizar perfiles de nacimiento significativos dentro de la población mexicana del año 2024 mediante la aplicación de algoritmos de clustering, con el fin de descubrir estructuras latentes que informen sobre factores de riesgo, patrones de salud y la calidad de la información registrada.

1.1.2. Objetivos Específicos

- Realizar un preprocesamiento exhaustivo del dataset, incluyendo la consolidación de registros, la imputación de valores faltantes y la estandarización de variables para optimizar los datos para el modelado.
- Determinar el número óptimo de clústeres (perfiles) mediante el método del codo, asegurando una base cuantitativa para la segmentación.
- Entrenar, comparar y evaluar tres modelos de clustering distintos (**K-Means**, **Gaussian Mixture Models** y **DBSCAN**) para garantizar la robustez y consistencia de los perfiles identificados.
- Analizar e interpretar los centroides o medias de los clústeres resultantes para asignar un significado clínico y demográfico a cada perfil, traduciendo las métricas estadísticas en descripciones cualitativas.
- Identificar perfiles de particular interés: aquellos de **alto riesgo médico** (ej. prematuridad), perfiles definidos por **factores demográficos** (ej. edad, escolaridad) y perfiles que revelen patrones de **datos faltantes o anómalos**.
- Visualizar la estructura de los clústeres y las diferencias entre perfiles utilizando reducción de dimensionalidad (PCA) y gráficos comparativos (boxplots, heatmaps) para comunicar los hallazgos de manera clara y efectiva.

1.2. Metodología Utilizada

El enfoque metodológico se estructuró en las siguientes etapas clave para manejar el dataset a gran escala y extraer perfiles significativos:

- **Adquisición del Dataset:** Se utilizó la base de datos pública de nacimientos (SINAC) para el año **2024**, proporcionada por la Dirección General de Información en Salud (DGIS).
- **Preprocesamiento y Preparación de Datos:** Esta fase crítica incluyó la normalización de nombres de columnas, el mapeo de códigos numéricos a sus descripciones textuales, el tratamiento de códigos especiales (ej. 99) como valores faltantes, y la imputación de dichos faltantes con la mediana o la moda según correspondiera.
- **Selección y Escalado de Características:** Se seleccionó un subconjunto de 11 variables clave. Todas fueron escaladas utilizando **StandardScaler** para que cada una contribuyera equitativamente a los cálculos de distancia de los algoritmos.

- **Modelado No Supervisado:** Se implementaron tres algoritmos: **K-Means** (con la variante `MiniBatchKMeans` para eficiencia), **Gaussian Mixture Models (GMM)** para flexibilidad en la forma de los clústeres, y **DBSCAN** para identificar grupos basados en densidad y aislar outliers. El número óptimo de clústeres para K-Means y GMM se estableció en 8, según el método del codo.
- **Análisis e Interpretación de Clústeres:** Los perfiles se analizaron cuantitativamente examinando las medias de cada grupo, tras revertir el escalado. La calidad de la separación se evaluó con la Puntuación de Silueta, y los hallazgos se visualizaron mediante gráficos 3D (vía PCA), heatmaps y boxplots comparativos.

1.3. Hipótesis del Análisis

Dado el carácter exploratorio del clustering, las hipótesis guían la interpretación de los patrones que se espera que los algoritmos descubran:

- **H1:** Se identificarán clústeres de **"Alto Riesgo Médico"** claramente definidos por una combinación de baja edad gestacional, bajo peso y bajas puntuaciones APGAR.
- **H2:** Surgirán perfiles definidos principalmente por **variables demográficas**, como clústeres que agrupen a madres jóvenes vs. madres de mayor edad, o perfiles diferenciados por el nivel de escolaridad.
- **H3:** Los algoritmos funcionarán como una herramienta de **detección de anomalías**, generando clústeres de calidad de datos cuya característica unificadora es un patrón de datos faltantes o inconsistentes en variables clave (ej. peso, APGAR).

2. Descripción del Dataset

El conjunto de datos utilizado en este análisis proviene de la base de datos de nacimientos (SINAC) para el año **2024**, administrada por la Dirección General de Información en Salud (DGIS) de México. Este dataset consolida la información registrada en los certificados de nacimiento a nivel nacional, representando una fuente de información demográfica y clínica de gran escala y detalle. El conjunto de datos completo para el año consta de aproximadamente 8 millones de registros.

Para el análisis de clustering no supervisado, se seleccionó un subconjunto de **11 variables clave**. La selección se realizó con el objetivo de construir perfiles de nacimiento basados en tres dimensiones fundamentales: las características demográficas de la madre, la calidad y prontitud del cuidado prenatal, y las condiciones médicas del recién nacido al momento

del parto. Esta selección permite a los algoritmos identificar patrones multifactoriales que combinan aspectos sociales, conductuales y clínicos.

A continuación, se presenta el diccionario de datos correspondiente a las variables utilizadas para el modelado de Machine Learning.

Variable	Descripción	Tipo
Características Demográficas de la Madre		
EDAD	Edad de la madre en años cumplidos.	Numérica
ESTADOCONYUGAL	Código numérico que representa el estado conyugal de la madre (ej. soltera, casada).	Categórica
ESCOLARIDAD	Código numérico para el nivel máximo de escolaridad alcanzado por la madre.	Categórica
SECONSIDERAINDIGI	Código que indica si la madre se autoidentifica como indígena (1=Sí, 2=No, 9=Se ignora).	Categórica
Cuidado Prenatal		
TOTALCONSULTAS	Número total de consultas de atención prenatal recibidas durante el embarazo.	Numérica
TRIMESTREPRIMERC	Trimestre en el que se realizó la primera consulta prenatal.	Categórica
Características del Recién Nacido		
EDADGESTACIONAL	Semanas de gestación cumplidas al momento del nacimiento.	Numérica
PESO	Peso del recién nacido, registrado en gramos.	Numérica
TALLA	Talla (longitud) del recién nacido, registrada en centímetros.	Numérica
APGAR	Puntuación APGAR evaluada al primer minuto de vida (escala 0-10).	Numérica
SEXO	Sexo del recién nacido (1=Hombre, 2=Mujer).	Categórica

Cuadro 1: Diccionario de datos de las variables seleccionadas para el clustering.

El subconjunto de datos final utilizado para el entrenamiento de los modelos consta de **11 variables** (5 numéricas y 6 categóricas) extraídas de la totalidad de registros de 2024. Esta mezcla rica de tipos de variables requiere un preprocesamiento cuidadoso, incluyendo

el manejo de códigos especiales y el escalado de datos, para asegurar que los algoritmos de clustering puedan procesar la información de manera efectiva y sin sesgos.

3. Limpieza y Preprocesamiento de Datos

El preprocesamiento de los datos fue una fase crítica y multifacética, diseñada para transformar los datos crudos del SINAC en un conjunto de datos limpio, estructurado y optimizado para los algoritmos de Machine Learning. A diferencia de un dataset sintético, los datos reales de registro presentaron desafíos significativos que requirieron un tratamiento cuidadoso.

3.1. Integración y Consolidación de Datos

El primer paso consistió en la consolidación de las diversas fuentes de información.

- **Unión de Tablas de Nacimientos:** Las tablas anuales de nacimientos (en este caso, la del 2024) fueron cargadas y consolidadas en un único DataFrame de Pandas.
- **Carga y Estandarización de Catálogos:** Se cargaron múltiples archivos de catálogos oficiales. Cada catálogo fue estandarizado para tener una estructura consistente de CLAVE y DESCRIPCION, tratando las claves como texto para evitar inconsistencias (ej. '1' vs '01').
- **Manejo de Catálogos Especiales:** El catálogo de establecimientos de salud (CLUES), al tener una estructura multidimensional, fue aislado durante la carga para ser tratado posteriormente mediante una fusión de tablas (`merge`) en lugar de un mapeo simple.

3.2. Normalización y Enriquecimiento de Datos

Para mejorar la legibilidad y facilitar el análisis, se realizaron las siguientes transformaciones:

- **Normalización de Nombres:** Los nombres de todas las columnas, tanto del dataset principal como de los catálogos, fueron normalizados programáticamente. Este proceso incluyó la conversión a mayúsculas y la eliminación de tildes y caracteres especiales, asegurando consistencia.
- **Mapeo de Códigos a Descripciones:** Se implementó una estrategia de mapeo híbrida (manual y automática) para reemplazar los códigos numéricos de las variables

categorías por sus descripciones textuales. Esto creó nuevas columnas con el sufijo `_DESC` (ej. `SEXO_DESC`), enriqueciendo el dataset para el análisis descriptivo.

3.3. Preparación para Clustering No Supervisado

Esta sub-etapa fue fundamental para adecuar los datos a los requerimientos de los algoritmos de clustering, que son sensibles a la escala y a los valores faltantes.

3.3.1. Manejo de Valores Faltantes y Códigos Especiales

Los algoritmos de clustering no pueden operar con datos nulos. El tratamiento se realizó en dos pasos:

1. **Identificación de Faltantes Implícitos:** Los códigos numéricos que representan información no especificada (ej. 99 para 'EDADGESTACIONAL', 9999 para 'PESO') fueron programáticamente reemplazados por valores nulos ('NaN') para asegurar que no fueran tratados como valores numéricos reales.
2. **Imputación de Datos:** Los valores 'NaN' resultantes fueron imputados utilizando estrategias estadísticas robustas. Para las variables numéricas continuas se utilizó la **mediana**, mientras que para las variables categóricas se utilizó la **moda**.

El siguiente fragmento de código ilustra la lógica de imputación aplicada:

```
1  # Ejemplo de reemplazo de códigos especiales por NaN
2  valores_a_reemplazar = {
3      'EDADGESTACIONAL': {99: np.nan},
4      'PESO': {9999: np.nan},
5      'APGAR': {99: np.nan}
6  }
7  df_ml.replace(valores_a_reemplazar, inplace=True)
8
9  # Lógica de imputación con mediana y moda
10 for columna in df_ml.columns:
11     if df_ml[columna].isnull().any():
12         if columna in ['PESO', 'TALLA', 'EDADGESTACIONAL']:
13             # Imputación con la mediana para variables numéricas
14             mediana = df_ml[columna].median()
15             df_ml[columna].fillna(mediana, inplace=True)
16         else:
17             # Imputación con la moda para variables categóricas
```

```
18         moda = df_ml[columna].mode()[0]
19         df_ml[columna].fillna(moda, inplace=True)
```

3.3.2. Escalado de Características

Dado que los algoritmos de clustering basados en distancia son sensibles a la escala de las variables, todas las 11 características seleccionadas fueron estandarizadas. Se utilizó el `StandardScaler` de Scikit-learn, que transforma cada variable para que tenga una media de 0 y una desviación estándar de 1. Este paso asegura que variables con rangos amplios (como ‘PESO’) no dominen a variables con rangos pequeños (como ‘SEXO’).

```
1 from sklearn.preprocessing import StandardScaler
2
3 scaler = StandardScaler()
4 X_scaled = scaler.fit_transform(df_ml)
```

Tras completar este riguroso proceso, se obtuvo un conjunto de datos numérico, sin valores faltantes y con todas sus características en una escala comparable, dejándolo en condiciones óptimas para ser procesado por los modelos de Machine Learning.

4. Análisis Descriptivo Rápido

Una vez consolidado y enriquecido el dataset, se realizó un análisis descriptivo rápido para obtener una primera visión de las características de los datos. Este análisis se centró en tres áreas clave: la identificación de valores faltantes, el resumen estadístico de las variables numéricas críticas y la visualización de la distribución de las variables categóricas más relevantes.

4.1. Análisis de Valores Faltantes

El primer paso en cualquier análisis es comprender qué información está ausente. Se calculó el porcentaje de valores nulos para cada columna del dataset enriquecido (utilizando las columnas con descripciones). Este análisis reveló que las variables relacionadas con la geografía detallada del parto y la certificación eran las que presentaban mayor cantidad de datos faltantes, con más del 90 % de ausencias. Por el contrario, la mayoría de las variables demográficas y clínicas clave mostraron una alta completitud.

Este hallazgo fue fundamental para la posterior selección de variables para el clustering, ya que se priorizaron aquellas con mayor disponibilidad y robustez de datos.

4.2. Estadísticas Centrales de Variables Numéricas

Para las variables numéricas más importantes en un registro de nacimiento, se calcularon las estadísticas de tendencia central (promedio, mediana) y de dispersión (desviación estándar). Antes del cálculo, fue crucial excluir los códigos numéricos utilizados para indicar "No especificado" (ej. 9999 para 'PESO'), reemplazándolos por valores nulos para no distorsionar los resultados.

Métrica	PESO (gramos)	TALLA (cm)	EDADGESTACIONAL (sem)
Promedio	3109.4	49.5	38.5
Mediana	3115.0	50.0	39.0
Desviación Estándar	471.1	2.9	1.8

Cuadro 2: Estadísticas centrales para variables numéricas clave.

Los resultados (Tabla 2) muestran que, en promedio, los recién nacidos en 2024 tuvieron un peso de aproximadamente 3109 gramos y una edad gestacional de 38.5 semanas, ambos indicadores dentro de los rangos considerados saludables a nivel poblacional. La cercanía entre la media y la mediana sugiere distribuciones relativamente simétricas para estas variables.

4.3. Visualización de Variables Categóricas Clave

Para comprender la distribución de las variables categóricas, se generaron gráficos de barras utilizando las columnas descriptivas (sufijo _DESC) creadas durante el preprocesamiento. Estas visualizaciones permitieron analizar de forma intuitiva la frecuencia de cada categoría.




Figura 1: Distribución de nacimientos según el lugar de ocurrencia. Se observa una abrumadora mayoría de nacimientos en unidades medicas privadas y en la Secretaría de Salud .

Como se observa en la Figura 1, la gran mayoría de los partos ocurren en hospitales privados y clínicas de la Secretaría de Salud, seguidos de cerca por las unidades del IMSS. Esto subraya el papel central del sistema de salud público en la atención materno-infantil en México.




Figura 2: Distribución de la escolaridad de la madre. Los niveles de secundaria y preparatoria completa son los más frecuentes.

La distribución de la escolaridad de la madre (Figura 2) muestra una concentración en los niveles de educación media (secundaria y preparatoria/bachillerato), lo cual proporciona un contexto socioeconómico importante para el análisis de los perfiles de nacimiento.

Este análisis descriptivo inicial proporcionó una comprensión fundamental de las características del dataset, validó la calidad de las variables seleccionadas y sentó las bases para la fase de modelado no supervisado.

5. Análisis de Clustering y Perfiles de Nacimiento

Para descubrir las estructuras latentes en los datos, se aplicaron tres algoritmos de clustering no supervisado. El número óptimo de clústeres para los modelos K-Means y GMM se determinó en **ocho (8)** mediante el método del codo, identificando el punto de inflexión donde la adición de más clústeres ya no aportaba una mejora significativa en la inercia del modelo.

5.1. Resultados del Modelo K-Means

El algoritmo K-Means, implementado con su variante optimizada `MiniBatchKMeans`, segmentó la población en ocho perfiles distintos. El análisis de los centroides de cada clúster reveló una clara diferenciación basada en una combinación de factores demográficos, de cuidado prenatal y de resultados del recién nacido. Se identificaron perfiles como **"Madre Joven con Cuidado Prenatal Tardío"**, un perfil de **Alto Riesgo Médico** y un grupo definido por **"Madre de Mayor Edad con Escolaridad Básica"**.

5.2. Resultados del Modelo Gaussian Mixture (GMM)

El modelo GMM, al ser más flexible en la forma de los clústeres, ofreció una segmentación más matizada y precisa, validando y refinando los hallazgos de K-Means. Los ocho perfiles identificados por GMM fueron particularmente reveladores:

- **Perfiles de Riesgo y Salud:** Se aisló con gran precisión un perfil de **"Muy Alto Riesgo Médico"** (Perfil 5), caracterizado por prematuridad severa y puntuaciones APGAR críticas.
- **Perfiles Demográficos:** El modelo fue capaz de generar clústeres casi puros basados en el sexo del recién nacido, identificando un perfil de **"Nacimiento Saludable (Mujeres)"** (Perfil 2) y su contraparte de **"Nacimiento Saludable (Varones)"** (Perfil 6).

- **Perfiles de Calidad de Datos:** Un hallazgo crucial fue la capacidad de GMM para funcionar como una herramienta de detección de anomalías. Creó tres clústeres distintos (Perfiles 1, 4 y 7) cuya característica definitoria era un patrón de datos faltantes o inconsistentes en variables clave como ‘PESO’, ‘APGAR’ o ‘SECONSIDERAINDIGENA’.

Estos resultados validaron las hipótesis H1, H2 y H3, demostrando que los algoritmos pueden identificar tanto perfiles clínicos como patrones en la calidad de la información.



Figura 3: Heatmap comparativo de los 8 perfiles encontrados por el modelo GMM. Los valores están normalizados (0 a 1) para una comparación visual justa. Celdas más brillantes indican valores más altos para esa característica.

5.3. Resultados del Modelo DBSCAN

DBSCAN ofreció una perspectiva completamente diferente, basada en la densidad de los datos. Sus resultados confirmaron la estructura general encontrada por los otros modelos, pero desde un ángulo distinto:

- **Núcleo Normativo (Clúster 0):** Identificó un clúster masivo que contenía más del 90 % de los datos, representando el "nacimiento estándar.^{en} México.
- **Clústeres Satélite:** Descubrió varios clústeres pequeños y densos en la periferia del núcleo. Estos "satélites" correspondían a los perfiles de alto riesgo y de calidad de datos que GMM había identificado, validando su existencia como grupos estadísticamente significativos y distintos de la norma.
- **Detección de Ruido (Outliers):** Clasificó a un pequeño número de registros como "ruido" (clúster -1). Estos puntos representan los casos más anómalos y únicos del dataset, que no encajan en ningún grupo denso.




Figura 4: Visualización de los clústeres de DBSCAN tras reducir la dimensionalidad con PCA. Se observa el gran núcleo (Clúster 0), los clústeres satélite en la periferia (colores) y los puntos de ruido (morado oscuro).

5.4. Comparación Visual de Perfiles (Boxplots)

Para profundizar en las diferencias entre los perfiles de GMM, se generaron diagramas de caja (boxplots) comparativos para las variables numéricas clave. La Figura 5 ilustra de manera contundente la distribución de cada variable a través de los ocho perfiles.

Comparación de Variables Clave entre 8 Perfiles (CLUSTER_GMM)




Figura 5: Comparación de la distribución de variables clave entre los 8 perfiles identificados por GMM. El gráfico para ‘EDADGESTACIONAL’, por ejemplo, muestra claramente cómo el Perfil 5 se encuentra muy por debajo de los demás, confirmando su naturaleza prematura.

El análisis conjunto de estos tres modelos proporciona una visión robusta y multifacética de la estructura de la población de nacimientos, validando la existencia de perfiles de riesgo, grupos demográficos específicos y patrones relacionados con la calidad de los datos.

6. Hallazgos Relevantes del Análisis de Clustering

El análisis de clustering no supervisado reveló una estructura compleja y significativa dentro del dataset de nacimientos, validando las hipótesis iniciales y descubriendo patrones no evidentes. Los hallazgos se pueden agrupar en tres categorías principales, con el modelo GMM proporcionando la segmentación más detallada y precisa.

6.1. Hallazgo 1: Identificación Precisa de un Perfil de Muy Alto Riesgo Médico

El descubrimiento más crítico fue la capacidad de los algoritmos, en particular GMM, para aislar un perfil de "**Muy Alto Riesgo Médico**" (Perfil 5). Este grupo, aunque representa

una pequeña fracción de la población, se caracteriza por una combinación de indicadores clínicos adversos:

- **Prematuridad Severa:** Con una edad gestacional promedio de **34.4 semanas**, este perfil se sitúa muy por debajo del umbral de nacimiento a término (37 semanas).
- **Bajo Peso Crítico:** El peso promedio de **2,110 gramos** está significativamente por debajo del límite de 2,500 gramos, indicando un alto riesgo de complicaciones.
- **Dificultad al Nacer:** La puntuación APGAR promedio de **5.1** es extremadamente baja, lo que sugiere que estos recién nacidos requirieron intervención médica inmediata para estabilizar su respiración o ritmo cardíaco.

Este hallazgo valida la hipótesis H1 y demuestra la capacidad del clustering para identificar automáticamente a la población de recién nacidos más vulnerable, un grupo prioritario para cualquier intervención de salud neonatal.




Figura 6: Diagrama de caja que compara la Edad Gestacional entre los 8 perfiles de GMM. La marcada diferencia del Perfil 5 (extremo izquierdo) ilustra su naturaleza prematura en comparación con los demás perfiles, que se agrupan en el rango de nacimientos a término.

6.2. Hallazgo 2: Segmentación Demográfica Clara y Patrones de Cuidado

En línea con la hipótesis H2, el análisis reveló varios perfiles definidos principalmente por características demográficas y de comportamiento. Los más notables fueron:

- **Segmentación por Sexo:** GMM identificó dos perfiles casi puros, uno compuesto exclusivamente por **mujeres** (Perfil 2) y otro por **hombres** (Perfil 6), ambos con indicadores de salud excelentes. Esto sugiere que, aunque sutiles, las diferencias asociadas al sexo fueron suficientes para que el algoritmo creara una segmentación.
- **Perfil de Cuidado Óptimo:** Se identificó un perfil de **Cuidado Prenatal Óptimo**" (Perfil 3), caracterizado por madres que inician su cuidado en el primer trimestre y tienen un seguimiento completo. Este grupo sirve como un punto de referencia del escenario ideal.
- **Perfil de Cuidado Tardío:** A la inversa, K-Means identificó un perfil de **"Madre Joven con Cuidado Prenatal Tardío"**, confirmando que la combinación de edad y prontitud en la atención médica es un factor de segmentación importante.

Estos perfiles demuestran que el clustering puede ser una herramienta poderosa para entender diferentes segmentos de la población y sus conductas de salud, permitiendo diseñar campañas de comunicación o apoyo más específicas.

6.3. Hallazgo 3: Clustering como Herramienta de Auditoría de Datos

Quizás el hallazgo más inesperado y valioso, validando la hipótesis H3, fue la capacidad de GMM y DBSCAN para funcionar como un sistema de **detección de anomalías y auditoría de la calidad de los datos**.

- **Clústeres de Datos Faltantes:** GMM generó tres perfiles distintos (Perfiles 1, 4 y 7) cuya característica unificadora no era un patrón clínico, sino un dato faltante o código especial en variables críticas como 'PESO' (9999), 'APGAR' (99) o 'SECONSIDERAINDIGENA' (9).
- **Identificación de Ruido:** DBSCAN clasificó explícitamente a 271 registros como ruido.^o outliers, aislándolos como los casos más únicos o anómalos del dataset, que merecen una investigación individual para detectar posibles errores de registro o casos clínicos excepcionales.

Este resultado demuestra que el clustering no supervisado no solo sirve para encontrar perfiles de personas, sino también para identificar sistemáticamente problemas en la calidad de la recolección de datos a gran escala, un hallazgo de gran valor para la administración de sistemas de información en salud.

7. Conclusiones

Este análisis exploratorio permitió caracterizar, segmentar e interpretar un conjunto de datos simulados con base en siete variables sociodemográficas y tecnológicas. A pesar de su origen sintético, los datos fueron tratados como si provinieran de una encuesta real, siguiendo prácticas estándar de minería de datos.

A partir del análisis descriptivo y multivariado, se identificaron relaciones clave como:

- Alta correlación entre el uso frecuente de tecnología y el interés por la inteligencia artificial.
- Diferencias claras en la elección del dispositivo favorito según el rango de edad.
- Segmentación ocupacional coherente con el nivel educativo declarado.

El uso de visualizaciones fue fundamental para descubrir patrones que no serían evidentes con estadística tabular. Por ejemplo, el boxplot de edad vs. dispositivo favorito y el mapa de calor de correlación aportaron claridad visual sobre perfiles de usuario y vínculos entre variables.

Implicaciones prácticas

Los resultados son útiles para:

- Diseñar programas de formación tecnológica adaptados a perfiles demográficos.
- Identificar segmentos potenciales para difusión de herramientas de IA.
- Servir de base para proyectos de recomendación, segmentación de mercado o predicción de afinidad tecnológica.

Reflexiones metodológicas

Aunque los datos fueron generados artificialmente, el análisis demostró la aplicabilidad de metodologías EDA para:

1. Validar pipelines de análisis.
2. Diseñar dashboards o visualizaciones interactivas.
3. Practicar procesos reales de limpieza, codificación y exploración.

Líneas futuras

Para consolidar este ejercicio, se propone:

- Repetir el análisis con datos reales recolectados mediante formularios o APIs educativas.
- Incorporar variables adicionales como ingreso, zona geográfica o hábitos digitales.
- Construir modelos predictivos a partir de las variables actuales, como regresiones logísticas o árboles de decisión.

Finalmente, este tipo de análisis permite consolidar competencias clave en minería de datos: desde la limpieza y exploración hasta la generación de conocimiento accionable.

Anexos

A. Diccionario de Datos Completo (SINAC)

A continuación, se presenta una descripción de un subconjunto más amplio de variables disponibles en el dataset original de SINAC, para dar contexto sobre la riqueza de la fuente de datos.

Variable Normalizada	Descripción
EDAD	Edad de la madre en años.
ESTADOCONYUGAL	Estado conyugal de la madre.
ESCOLARIDAD	Nivel máximo de escolaridad de la madre.
SECONSIDERAINDIGENA	Autoadscripción indígena de la madre.
TOTALCONSULTAS	Número total de consultas prenatales.
TRIMESTREPRIMERCONSULTA	Trimestre de la primera consulta prenatal.
AFILIACION	Institución de derechohabencia de la madre.
NUMEROEMBARAZOS	Número total de embarazos de la madre.
EDADGESTACIONAL	Semanas de gestación del recién nacido.
PESO	Peso del recién nacido en gramos.

Cuadro 3 – continuación	
Variable Normalizada	Descripción
TALLA	Talla del recién nacido en centímetros.
APGAR	Puntuación APGAR al primer minuto.
SEXO	Sexo del recién nacido.
LUGARNACIMIENTO	Lugar donde ocurrió el nacimiento (ej. Hospital, Domicilio).
PERSONALATENDIO	Persona que atendió el parto (ej. Médico, Partera).

Cuadro 3: Selección del diccionario de datos del SINAC.

B. Perfiles de Clústeres (Resultados de GMM)

La siguiente tabla muestra los valores promedio (medias) para cada una de las 11 variables utilizadas en el modelado, para cada uno de los 8 perfiles identificados por el algoritmo Gaussian Mixture Model. Estos valores numéricos son la base para la interpretación cualitativa presentada en la sección de Hallazgos.

Perfil SEXO	EDAD	EST.CONY.	ESCOL.	INDIGENA	CONSULTAS	TRIM.INI.	GESTAC.	PESO	TALLA	APGAR
0 1.5	25.8	3.9	56.6	1.8	16.5	6.7	37.9	4035	48.6	8.0
1 1.6	26.1	3.9	59.6	1.9	7.2	1.2	38.4	9999	47.6	8.8
2 2.0	25.1	3.2	57.4	1.7	6.2	1.6	38.7	3069	49.5	8.9
3 1.5	27.1	4.4	65.7	2.0	8.7	1.0	38.5	3109	49.6	8.9
4 1.5	26.0	4.2	62.1	9.0	7.5	1.7	38.4	3393	49.8	8.8
5 1.4	26.7	3.8	61.0	1.9	6.3	1.2	34.4	2110	42.5	5.1
6 1.0	25.1	3.2	57.3	1.7	6.1	1.6	38.7	3120	49.8	8.9
7 1.5	26.0	4.0	51.3	1.5	18.5	1.4	39.3	3760	49.9	99.0

Cuadro 4: Tabla de medias de los perfiles identificados por el modelo GMM. Valores como 9999, 99.0 o 9.0 representan códigos de "No especificado".

C. Ejemplo de Código: Entrenamiento del Modelo GMM

A continuación se muestra un fragmento del código utilizado para entrenar el modelo Gaussian Mixture, que demostró ser el más efectivo para la segmentación. El enfoque consistió en entrenar el modelo en una muestra grande y luego predecir las etiquetas para todo el dataset.

```

1 from sklearn.mixture import GaussianMixture
2 import numpy as np

```

```

3
4  # Tomar una muestra grande (ej. 200,000) para el entrenamiento
5  sample_size_gmm = 200000
6  random_indices_gmm = np.random.choice(X_scaled.shape[0],
7                                         size=sample_size_gmm,
8                                         replace=False)
9  X_gmm_train = X_scaled[random_indices_gmm, :]
10
11 # Configurar y entrenar el modelo GMM
12 K_OPTIMO = 8
13 gmm = GaussianMixture(n_components=K_OPTIMO, random_state=42, n_init=5)
14 gmm.fit(X_gmm_train)
15
16 # Asignar las etiquetas de clúster a todo el conjunto de datos
17 gmm_labels = gmm.predict(X_scaled)
18 df_nacimientos['CLUSTER_GMM'] = gmm_labels

```

D. Recomendaciones de Reproducibilidad

Para asegurar la reproducibilidad de este análisis, se deben considerar los siguientes puntos:

- **Fuente de Datos:** Utilizar la base de datos de nacimientos (SINAC) del año 2024, disponible en el portal de la DGIS.
- **Software y Librerías:** El análisis se realizó en Python 3. Las librerías principales utilizadas fueron `pandas` para la manipulación de datos, `scikit-learn` para el pre-procesamiento y los modelos de Machine Learning, y `matplotlib/seaborn` para las visualizaciones.
- **Semilla Aleatoria:** Se utilizó una semilla aleatoria (`'random_state = 42'`) en los algoritmos de clustering.
- **Parámetros del Modelo:** Para reproducir los resultados de DBSCAN, es crucial utilizar los mismos parámetros de `eps` (3.0) y `min_samples` (25), que fueron determinados empíricamente.

Referencias

- [1] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD'96)*, pages 226–231. AAAI Press, 1996.
- [2] J. D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [3] Wes McKinney. Data structures for statistical computing in python. In Stéfan van der Walt and Jarrod Millman, editors, *Proceedings of the 9th Python in Science Conference*, pages 56–61, 2010.
- [4] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [5] Secretaría de Salud, Dirección General de Información en Salud (DGIS). Sub-sistema de información sobre nacimientos (sinac). base de datos de nacimientos 2024. http://www.dgis.salud.gob.mx/contenidos/basesdedatos/da_nacimientos_gobmx.html, 2025. Accedido en noviembre de 2025.
- [6] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, Reading, MA, 1977.
- [7] Michael L. Waskom. Seaborn: statistical data visualization, 2021.